Trabajo Práctico Grupal
Stacks Enterprise de Datos

Gestión y Arquitectura de Datos, Universidad de San Andrés

1. Introducción

A lo largo del curso vieron distintos paradigmas para gestionar datos: bases relacionales, normalización, SQL, y las cuatro grandes familias de NoSQL (documental, clave-valor, columnar y grafos). También discutimos el teorema CAP y los trade-offs que aparecen cuando un sistema crece.

En el mundo real, las empresas no usan una sola base de datos: combinan varias tecnologías en lo que se conoce como un **stack de datos**. Un stack es un conjunto de herramientas integradas que cubren todo el ciclo de vida del dato: ingesta, almacenamiento, procesamiento, transformación y consumo final (dashboards, reportes, aplicaciones).

El objetivo de este trabajo es que investiguen un stack enterprise real, entiendan cómo se integran sus piezas, y se lo expliquen al resto de la clase. Nos vamos a concentrar en los stacks de los tres grandes proveedores de cloud, que entre los tres se quedan con la mayor parte del mercado: es muy probable que en su primer trabajo terminen usando alguno. La presentación se realizará en la **Clase 10**, y servirá como punto de partida para la discusión sobre arquitecturas analíticas.

2. Modalidad

- Se dividirán en **grupos de 3 a 4 personas**.
- Cada grupo recibe un stack **por sorteo** al final de la Clase 9. Como hay más grupos que stacks, algunos stacks los van a presentar dos grupos. En ese caso, cada grupo arma su presentación por separado.
- La entrega consiste en una **presentación oral grupal** de 10 a 12 minutos, seguida de 5 minutos de preguntas.
- Las slides son obligatorias. Todos los integrantes deben hablar durante la exposición.

- La presentación se realiza en la **Clase 10** (martes 3/11).

3. Stacks Disponibles

3.1. Stack 1: Amazon Web Services (AWS)

AWS fue el primero en el negocio del cloud moderno (lanzó S3 en 2006) y hoy sigue siendo el que más mercado tiene. Su stack de datos es enorme: tiene un servicio para prácticamente cualquier problema, lo que también significa que hay que conocer muchas piezas para armar algo razonable.

S3 es la base de casi todo el stack analítico de AWS y probablemente sea el sistema de almacenamiento más usado del mundo. Comparado con los otros dos, AWS es más modular: te da las piezas, vos las integrás. Más flexibilidad, más complejidad. En los últimos años empezó a juntar sus herramientas de datos, analytics e IA bajo el paraguas de SageMaker, que dejó de ser solamente un producto de machine learning.

3.2. Stack 2: Microsoft Azure

El stack de datos de Microsoft. Donde más pega es en empresas que ya viven en el mundo Microsoft: Office 365, Teams, Active Directory, SQL Server. Si ya usás Power BI todos los días, Azure es el camino natural.

La pieza central hoy es Microsoft Fabric, lanzada en 2023: una plataforma SaaS que junta ingesta, data lake, data warehouse, procesamiento y Power BI en un solo producto, todo arriba de un único lago de datos llamado OneLake. Es la evolución de Synapse Analytics, que sigue existiendo pero ya no es donde Microsoft pone las fichas.

3.3. Stack 3: Google Cloud Platform (GCP)

El stack de datos de Google. Tiene sentido que sea uno de los más fuertes del mercado porque Google viene manejando volúmenes absurdos de datos desde hace décadas (búsqueda, YouTube, Gmail) y mucho de lo que después se volvió estándar en la industria salió de papers de Google: MapReduce, BigTable, Dremel.

El componente central es BigQuery, un data warehouse serverless. Serverless quiere decir que el usuario no administra ni servidores ni clusters: tira queries y Google se encarga del resto. En el modelo más común se cobra por la cantidad de datos que escanea cada query. Lo eligen mucho las empresas que no quieren pelearse con infraestructura, y cada vez más las que quieren usar las herramientas de IA de Google (Vertex AI, Gemini) directamente sobre sus datos.

4. Contenido de la Presentación

Al terminar su presentación, el resto de la clase tiene que entender qué es el stack que les tocó y cómo lo usaría una empresa para gestionar sus datos. Como mínimo, la presentación tiene que responder:

- ¿Qué es y qué problema resuelve?
- ¿Cómo se arma una plataforma de datos con este stack? Muéstrenlo con un **diagrama de arquitectura** que siga el recorrido de un dato desde que se genera hasta que alguien lo consume.
- ¿Cómo se relaciona con lo que vimos en la materia?
- ¿Cuándo conviene y cuándo no?

5. Recomendaciones

- **No se queden en el marketing.** Las páginas oficiales venden el producto. Busquen blogs técnicos, comparaciones independientes y casos de estudio reales. Los blogs de ingeniería de Spotify, Netflix, Uber o Airbnb suelen publicar sobre sus stacks.
- **No traten de cubrir todo.** Cada uno de estos stacks tiene decenas de servicios. Es mejor explicar 4-5 componentes bien que listar 15 superficialmente.
- **Practiquen la presentación** antes de la clase. 10-12 minutos pasan rápido.