

Arquitecturas Analíticas

Gestión y Arquitectura de Datos



- Permiten almacenar, procesar y analizar grandes volúmenes de datos
- Enfocadas en obtener conocimiento de datos históricos
- Integran datos de múltiples fuentes
- Requieren transformación y acceso eficiente para el análisis
- No hay una única solución, depende de la organización

Un Data Warehouse es un lugar centralizado donde guardás datos ya procesados y estructurados para hacer análisis.


El proceso usa herramientas ETL (Extract, Transform, Load): extraés los datos, los transformás para limpiarlos y normalizarlos, y los cargás en el warehouse.

“Schema-on-write”: los datos tienen que cumplir con un esquema predefinido antes de guardarlos. Esto garantiza consistencia y calidad, pero perdés flexibilidad.

Data Warehouse: características

- Pensados para consultas analíticas complejas sobre datos históricos
- Optimizados para múltiples usuarios haciendo consultas pesadas simultáneamente
- Arquitectura diseñada para lectura intensiva, no para escribir constantemente
- Datos estructurados y normalizados, más fáciles de consultar y analizar

Data Warehouse



Data Warehouse: ventajas y desventajas

Ventajas:

- Fuente única de verdad
- Datos validados y estructurados
- Los analistas pueden enfocarse en análisis en vez de limpiar datos

Desventajas:

- Construcción y mantenimiento costosos
- Puede llevar bastante tiempo
- Menos flexibilidad, especialmente con muchas fuentes diferentes

Data Lake


En un **Data Lake** guardás los datos en crudo, sin procesarlos mucho y sin que tengan que cumplir con un esquema específico cuando los cargás.

Schema-on-read: no definís el esquema antes de guardar, sino cuando leés los datos. Útil para datos no estructurados o semi-estructurados (logs, imágenes, videos, sensores).

La idea es capturar y guardar todo lo que puedas, incluso si todavía no sabés si va a ser útil. Como el almacenamiento es relativamente barato, no es tan costoso guardar datos que quizás no uses.

Riesgo: sin gobernanza, puede convertirse en un “data swamp”.

Data Lake



Data Lake: ventajas y desventajas

Ventajas:

- Flexibilidad para datos diversos
- Almacenamiento relativamente barato
- Útil para investigación y ML
- Permite guardar datos sin saber su uso futuro

Desventajas:


- Sin gobernanza puede ser difícil de usar
- Sin catalogación y metadata, difícil encontrar lo que guardaste
- Consultas más lentas: hay que procesar el esquema cada vez

Un Data Mart es un subconjunto de un Data Warehouse o Data Lake enfocado en un área específica, como un departamento o caso de uso particular.

En vez de que los usuarios naveguen por todo el warehouse, les das acceso solo a los datos que realmente necesitan. Esto hace que sea más rápido de consultar y más fácil de entender.

Pueden construirse como subconjuntos de un warehouse centralizado (mantiene consistencia) o directamente desde las fuentes de datos.

Data Mart



Data Mart: ventajas y desventajas

Ventajas:

- Acceso rápido y enfocado
- Más fácil de entender
- Optimizado para casos de uso específicos

Desventajas:

- Riesgo de inconsistencias
- Riesgo de diferentes versiones de los mismos datos
- Puede llevar a decisiones contradictorias

En la arquitectura Inmon primero construís un Data Warehouse corporativo integrado y normalizado, y después derivás los Data Marts específicos para cada área o departamento.

Enfoque bottom-up: primero la base corporativa, luego los Data Marts específicos.

El warehouse está normalizado (típicamente en tercera forma normal), sin redundancia. Es la única fuente de verdad: todos los Data Marts comparten la misma base de datos subyacente.


Arquitectura Inmon: características

Requiere bastante planificación y diseño inicial: identificar todas las fuentes de datos, entender cómo se relacionan, y diseñar un esquema normalizado. Tienes que saber muy bien lo que querés.

Los Data Marts son vistas o subconjuntos del warehouse corporativo. Cada uno está optimizado para las necesidades de un departamento específico, pero todos comparten la misma fuente de datos.

Esto puede llevar tiempo, pero el resultado es un sistema robusto y bien integrado.

Arquitectura Inmon



Arquitectura Inmon: ventajas y desventajas

Ventajas:

- Visión integrada y consistente
- Elimina inconsistencias que aparecen cuando cada departamento construye su propio sistema
- Sistema robusto y bien integrado
- Todos los análisis se basan en la misma información centralizada

Desventajas:

- Más lento de implementar inicialmente
- Hay que construir el warehouse antes de entregar valor
- Requiere identificar todas las fuentes desde el principio
- Puede llevar tiempo antes de ver resultados

En la arquitectura Kimball empezás construyendo Data Marts específicos que resuelven problemas concretos, y después gradualmente los integrás.

Enfoque top-down: primero los Data Marts específicos, luego la integración gradual.

En vez de construir un Data Warehouse corporativo completo desde el principio, identificás un caso de uso con valor claro y construís un Data Mart dimensional. Cuando funciona, construís el siguiente, y así.


Arquitectura Kimball: dimensiones conformadas

Las dimensiones conformadas permiten que los Data Marts se integren gradualmente sin perder consistencia.

Son dimensiones que se comparten entre múltiples Data Marts, con el mismo significado y estructura en todos ellos. Por ejemplo, una dimensión de tiempo o de producto que se usa de la misma forma en todos los Data Marts.

Esto garantiza consistencia y permite aprender y ajustar el enfoque basándose en los resultados antes de comprometerte con una arquitectura completa.

Arquitectura Kimball



Arquitectura Kimball: ventajas y desventajas

Ventajas:

- Podés entregar valor más rápido
- Al empezar con un Data Mart específico, tenés algo funcionando en mucho menos tiempo
- Permite aprender y ajustar el enfoque basándote en los resultados

Desventajas:

- Necesitás asegurarte de que los Data Marts se construyan de forma que puedan integrarse después
- Si no se planifican las dimensiones conformadas, la integración futura puede ser difícil
- Riesgo de inconsistencias similares a los que Inmon intenta evitar

Los modelos dimensionales son una forma de organizar datos pensada específicamente para facilitar el análisis y la consulta.

La estructura básica tiene dos tipos principales de tablas: tablas de hechos y tablas de dimensión.

Tablas de Hechos

- Tienen las métricas o medidas que querés analizar
- Ejemplos: ventas, ingresos, cantidad de productos vendidos
- Cualquier otra medida numérica relevante

Tablas de Dimensión

- Dan el contexto para analizar esos hechos
- Describen quién, qué, cuándo, dónde y cómo ocurrieron los hechos
- Ejemplos: tiempo, producto, cliente, ubicación

Modelo Dimensional Estrella


El modelo dimensional estrella se llama así porque la estructura se parece a una estrella: una tabla de hechos en el centro y múltiples tablas de dimensión conectadas directamente a ella. Este modelo es el más simple y común.

Modelo Estrella: estructura

La tabla de hechos tiene las medidas numéricas y claves foráneas que la conectan con cada tabla de dimensión.

Cada tabla de dimensión está completamente desnormalizada: toda la información relevante está guardada directamente en esa tabla. Por ejemplo, una dimensión de producto podría tener en una sola tabla: ID, nombre, categoría, marca, proveedor, precio, etc.

Modelo Dimensional Estrella



Modelo Estrella: ventajas y desventajas

Ventajas:

- Simplicidad: consultas típicas requieren solo un join
- Consultas más rápidas y fáciles de escribir
- Más intuitivo para usuarios finales

Desventajas:

- La desnormalización puede llevar a redundancia de datos
- Información de las dimensiones se repite para cada registro relacionado
- Redundancia consume espacio, aunque beneficio en simplicidad y rendimiento vale la pena

Modelo Dimensional Snowflake

El modelo dimensional snowflake es una variación del modelo estrella donde las tablas de dimensión están normalizadas, dividiéndose en múltiples tablas relacionadas.

La estructura se parece a un copo de nieve, con la tabla de hechos en el centro y las dimensiones extendiéndose en múltiples niveles.


Modelo Snowflake: estructura

En vez de tener toda la información de una dimensión en una sola tabla desnormalizada, la información se divide en múltiples tablas relacionadas.

Por ejemplo, en vez de una dimensión de producto con categoría, marca y proveedor directamente, un modelo snowflake podría tener tablas separadas de producto, categoría, marca y proveedor, todas relacionadas entre sí.

Esto crea una estructura jerárquica que se extiende en múltiples niveles, como los brazos de un copo de nieve.

Modelo Dimensional Snowflake



Modelo Snowflake: ventajas y desventajas

Ventajas:

- La normalización reduce la redundancia de datos
- Mantenimiento más fácil cuando hay cambios en la estructura
- Menor consumo de espacio

Desventajas:

- Las consultas se vuelven más complejas
- Requieren múltiples joins para reconstruir la información completa
- Consultas más lentas y difíciles de escribir y optimizar
- Menos intuitivo para usuarios finales

¿Dudas?
¿Consultas?



Universidad de
SanAndrés